

FORMELSAMLING i GO040A STATISTIKK

Grunnleggende formler i sannsynlighetsregningen

Generell addisjonssetning $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Betinget sannsynlighet $P(A|B) = \frac{P(A \cap B)}{P(B)}$

Gen. multiplikasjonsregel $P(A \cap B) = P(B) \cdot P(A|B)$ eller $P(A \cap B) = P(A) \cdot P(B|A)$

Total sannsynlighet $P(A) = \sum_{i=1}^r P(B_i) \cdot P(A|B_i)$ **Bayes lov** $P(B|A) = \frac{P(B) \cdot P(A|B)}{P(A)}$

A og B uavhengige $P(A \cap B) = P(A) \cdot P(B)$ $P(A|B) = P(A)$ $P(B|A) = P(B)$

Kombinatorikk

Antall forskjellige utvalg når s enheter trekkes fra en populasjon på N enheter:

Ordnet utvalg, med tilbakelegging N^s

Ordnet utvalg, uten tilbakelegging $(N)_s = N(N-1) \cdots (N-s+1) = \frac{N!}{(N-s)!}$

Uordnet utvalg, uten tilbakelegging $\binom{N}{s} = \frac{(N)_s}{s!} = \frac{N!}{s!(N-s)!}$

Generelt om sannsynlighetsfordelinger for 1 variabel

Fordelingsfunksjon $F(x) = P(X \leq x)$ $F(x) = \int_{-\infty}^x f(u) du$
 $f(x) = F'(x)$ $P(a < X \leq b) = F(b) - F(a)$

Forventning $\mu = E(X) = \sum_x x \cdot P(X = x)$ $\mu = E(X) = \int_{-\infty}^{\infty} x \cdot f(x) dx$
 $E[g(X)] = \sum_x g(x) \cdot P(X = x)$ $E[g(X)] = \int_{-\infty}^{\infty} g(x) \cdot f(x) dx$

Varsians $\sigma^2 = \text{Var}(X) = E[(X - \mu)^2] = E(X^2) - \mu^2$

Standardavvik $\sigma = \text{SD}(X) = \sqrt{\text{Var}(X)}$

Generelt om sannsynlighetsfordelinger for 2 variable

Simultanfordeling for X og Y $P[(X = x) \cap (Y = y)]$

Forventning $E[g(X, Y)] = \sum_x \sum_y g(x, y) \cdot P[(X = x) \cap (Y = y)]$

Kovarians $\text{Cov}(X, Y) = E[(X - \mu_1)(Y - \mu_2)] = E(X \cdot Y) - \mu_1 \cdot \mu_2$

Korrelasjonskoeffisient $\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_1 \cdot \sigma_2}$

Spesielle diskrete sannsynlighetsfordelinger

Binomisk fordeling

$X \sim \text{bin}(n, p)$:

$$P(X = x) = \binom{n}{x} \cdot p^x \cdot (1-p)^{n-x}$$

$$E(X) = np \qquad \text{Var}(X) = np \cdot (1-p)$$

Hypergeometrisk fordeling $X \sim \text{hypergeom}(N, M, n)$:

$$P(X = x) = \frac{\binom{M}{x} \cdot \binom{N-M}{n-x}}{\binom{N}{n}}$$

$$E(X) = n\theta \qquad \text{Var}(X) = \frac{N-n}{N-1} \cdot n\theta(1-\theta) \quad , \quad \text{der } \theta = \frac{M}{N}$$

Poissonfordeling

$X \sim \text{Po}(\lambda)$:

$$P(X = x) = \frac{\lambda^x}{x!} \cdot e^{-\lambda}$$

$$E(X) = \lambda \qquad \text{Var}(X) = \lambda$$

Spesielle kontinuerlige sannsynlighetsfordelinger

Eksponensialfordeling

$T \sim \text{eksp}(\lambda)$:

$$f(t) = \lambda \cdot e^{-\lambda t} \quad \text{for } t > 0 \qquad F(t) = 1 - e^{-\lambda t} \quad \text{for } t > 0$$

$$E(T) = \frac{1}{\lambda} \qquad \text{Var}(T) = \frac{1}{\lambda^2}$$

Rektangulær fordeling

$X \sim R(\alpha, \beta)$:

$$f(x) = \frac{1}{\beta - \alpha} \quad \text{for } \alpha < x < \beta$$

$$E(X) = \frac{\alpha + \beta}{2} \qquad \text{Var}(X) = \frac{1}{12} (\beta - \alpha)^2$$

Standard normalfordeling

$U \sim N(0, 1)$:

$$P(U \leq u) = G(u) \qquad G(-u) = 1 - G(u)$$

Generell normalfordeling

$X \sim N(\mu, \sigma^2)$:

$$F(x) = P(X \leq x) = G\left(\frac{x - \mu}{\sigma}\right)$$

Regler for forventning og varians

$$E(aX + b) = a E(X) + b$$

$$E(X_1 + X_2) = E(X_1) + E(X_2)$$

$$\text{Var}(aX + b) = a^2 \text{Var}(X)$$

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2), \text{ når } X_1 \text{ og } X_2 \text{ er uavhengige.}$$

Punktestimering av forventning μ og varians σ^2 i målemodellen

Punktestimator for forventning: $\hat{\mu} = \bar{X} = \frac{1}{n} \cdot \sum_{i=1}^n X_i$

$$E(\hat{\mu}) = \mu \qquad \text{Var}(\hat{\mu}) = \frac{\sigma^2}{n}$$

Punktestimator for varians: $S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \cdot (\sum_{i=1}^n X_i^2 - n \cdot \bar{X}^2)$

$$E(S^2) = \sigma^2$$

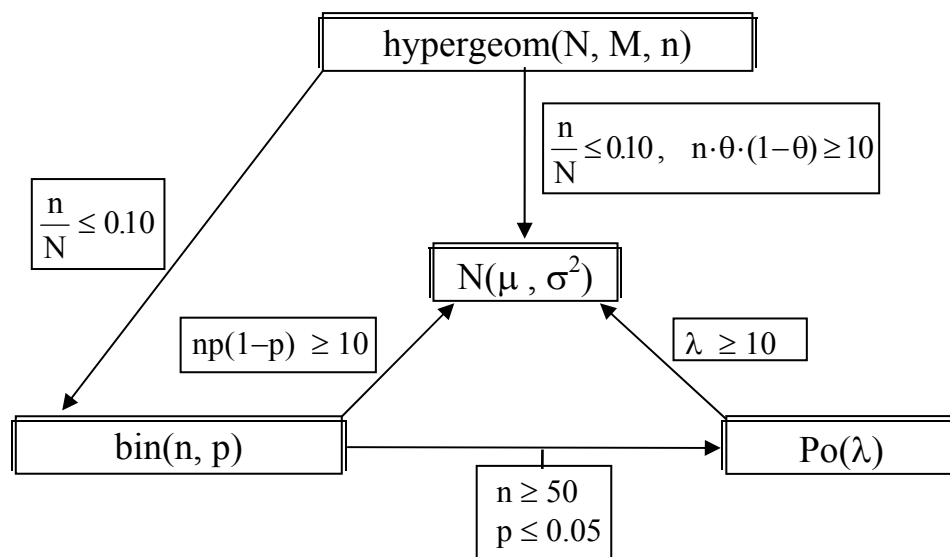
Tilnærminger

Sentralgrensesetningen (gjelder alle fordelinger):

Dersom X_1, X_2, \dots, X_n er uavhengige og identisk fordelte stokastiske variable med forventning μ og varians σ^2 , så er for *store* verdier av n ($n \geq 30$)

$$X_1 + X_2 + \dots + X_n \approx N(n\mu, n\sigma^2) \text{ og } \bar{X} = \frac{1}{n}(X_1 + X_2 + \dots + X_n) \approx N(\mu, \frac{\sigma^2}{n})$$

Sammenheng mellom spesielle fordelinger:



Intervallestimering og hypotesetesting i målemodellen

σ kjent, normalfordelte observasjoner eller stort antall observasjoner ($n \geq 30$):

$$(1-\alpha) \cdot 100\% \text{ konfidensintervall for forventningen } \mu: \quad \bar{X} \pm u_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$$

$$\text{Utvalgsstørrelse:} \quad n = \left(\frac{u_{\alpha/2} \cdot \sigma}{d} \right)^2, \text{ der } d \text{ er konfidensintervallets feilmargin.}$$

$$\text{Testobservator for } H_0: \mu = \mu_0: \quad U_0 = \frac{\bar{X} - \mu_0}{\frac{\sigma}{\sqrt{n}}} \sim N\left(\frac{\mu - \mu_0}{\frac{\sigma}{\sqrt{n}}}, 1\right)$$

σ ukjent, normalfordelte observasjoner:

$$(1-\alpha) \cdot 100\% \text{ konfidensintervall for forventningen } \mu: \quad \bar{X} \pm t_{\alpha/2, n-1} \cdot \frac{S}{\sqrt{n}}$$

$$\text{Testobservator for } H_0: \mu = \mu_0: \quad T_0 = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$$

Når H_0 er sann, er T_0 t-fordelt med $(n-1)$ frihetsgrader.

Intervallestimering og hypotesetesting i Poissonmodell, vha. normaltilnærming

$$\text{Tilnærmet } 100(1-\alpha)\% \text{ konfidensintervall for } \lambda: \quad \hat{\lambda} \pm u_{\alpha/2} \sqrt{\hat{\lambda}}, \text{ der } \hat{\lambda} = X$$

$$\text{Testobservator for } H_0: \lambda = \lambda_0: \quad U_0 = \frac{\hat{\lambda} - \lambda_0}{\sqrt{\lambda_0}}$$

Intervallestimering og hypotesetesting i binomisk modell, vha. normaltilnærming

$$\text{Tilnærmet } 100(1-\alpha)\% \text{ konfidensintervall for } p: \quad \hat{p} \pm u_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}, \text{ der } \hat{p} = \frac{X}{n}$$

$$\text{Testobservator for } H_0: p = p_0: \quad U_0 = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}}$$

Intervallestimering og hypotesetesting i hypergeometrisk modell, vha. normaltilnærming

$$\text{Tilnærmet } 100(1-\alpha)\% \text{ konfidensintervall for } \theta = \frac{M}{N}: \text{ Analogt med binomisk modell.}$$

$$\text{Testobservator for } H_0: \theta = \theta_0: \text{ Analogt med binomisk modell.}$$

Korrelasjon

$$S_X^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 ; \quad S_Y^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{n} \sum_{i=1}^n Y_i^2 - \bar{Y}^2$$
$$S_{XY} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{n} \sum_{i=1}^n X_i Y_i - \bar{X} \cdot \bar{Y}$$

Empirisk korrelasjonskoeffisient: $R = \frac{S_{XY}}{S_X S_Y}$

Regresjonsmodellen

n par observasjoner av x og Y: $(x_1, Y_1), (x_2, Y_2), \dots, (x_n, Y_n)$

Y_1, Y_2, \dots, Y_n er uavhengige og normalfordelte stokastiske variable.

$E(Y_i) = \beta_0 + \beta_1 x_i$, $i = 1, 2, \dots, n$; der x_1, x_2, \dots, x_n er kjente tall.

$\text{Var}(Y_i) = \sigma^2$, $i = 1, 2, \dots, n$.

Minste kvadraters estimatorer:

$$\hat{\beta}_1 = \frac{1}{M} \sum_{i=1}^n (x_i - \bar{x}) Y_i, \quad \text{der } M = \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

$$\hat{\beta}_1 \sim N\left(\beta_1, \frac{\sigma^2}{M}\right), \quad \hat{\beta}_0 \sim N\left(\beta_0, \frac{\sigma^2}{nM} \sum_{i=1}^n x_i^2\right)$$

Estimert regresjonslinje: $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 x$

Intervallestimering og hypotesetesting i regresjonsmodellen

σ kjent:

Konfidensintervall for β_1 : $\hat{\beta}_1 \pm u_{\alpha/2} \frac{\sigma}{\sqrt{M}}$

Testobservator for β_1 : $U_0 = \frac{\hat{\beta}_1 - \beta_1^0}{\sigma / \sqrt{M}} \sim N\left(\frac{\beta_1 - \beta_1^0}{\sigma / \sqrt{M}}, 1\right)$

σ ukjent: Ikke pensum

□